

Análise de Correlação Multivariada

Documentação técnica — modelos estatísticos, fórmulas e cálculo de estabilidade

Este documento descreve o que o programa faz e detalha os modelos estatísticos internos. A ferramenta foi concebida para engenheiros de processo identificarem a **causa** de aumentos ou reduções de um **indicador-chave** a partir de uma série de indicadores de processo, considerando o **atraso (lag)** entre causa e efeito.

1. Visão geral e fluxo de processamento

O programa recebe uma planilha com uma coluna de data/hora e várias colunas de indicadores. O usuário escolhe o indicador-chave (o efeito a explicar) e o sistema executa, em sequência:

- **Leitura e padronização** dos dados (numéricos, ordenados no tempo);
- **Reamostragem** numa grade temporal regular (ou agregação composta, no caso de variáveis de laboratório);
- **Deteção do lag ótimo** de cada indicador via correlação cruzada;
- **Quantificação da relação** por correlação de Pearson e Informação Mútua;
- **Atribuição rigorosa de variância** (Shapley/LMG) com tratamento de multicolinearidade;
- **Avaliação de estabilidade** de cada indicador e geração de gatilhos acionáveis.

2. Reamostragem temporal

O passo temporal é estimado pela mediana das diferenças entre instantes consecutivos:

$$\Delta t = \text{mediana} \{ t_{i+1} - t_i \}$$

Os dados são reamostrados para uma grade regular de passo Δt (média dentro de cada intervalo). Lacunas curtas (até 3 amostras consecutivas) são interpoladas linearmente; lacunas maiores permanecem vazias e são ignoradas nos cálculos.

3. Variáveis de laboratório (amostras compostas)

Variáveis medidas em laboratório por composição (ex.: a cada 4 horas) têm um valor que representa a **média do período**, e por isso **não podem ser interpoladas**. Sendo T o instante registrado (fim do período) e N o número de horas da composição, define-se a janela do período como:

$$W_T = (T - N, T]$$

Para cada coleta de laboratório em T , todos os indicadores são agregados pela média na janela, colocando processo e laboratório na mesma base composta:

$$\bar{X}_j(T) = \frac{1}{|W_T|} \sum_{t \in W_T} X_j(t)$$

As variáveis de laboratório, tendo um único valor na janela, resultam no próprio valor reportado. As demais análises seguem sobre esse conjunto composto (passo = N horas).

4. Detecção do lag ótimo (correlação cruzada / TLCC)

Para cada indicador, varre-se um conjunto de defasagens (lags) e calcula-se a correlação de Pearson entre o indicador-chave e o indicador deslocado no tempo. A correlação de Pearson é:

$$r = \frac{\sum_i (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_i (x_i - \bar{x})^2} \sqrt{\sum_i (y_i - \bar{y})^2}}$$

A função de correlação cruzada em função do lag ■ é:

$$r(\ell) = \text{corr}(\text{chave}_t, \text{indicador}_{t-\ell})$$

O lag ótimo é aquele que **maximiza o módulo** da correlação (captando tanto relações diretas quanto inversas):

$$\ell^* = \text{argmax}_{\ell} |r(\ell)|$$

E é convertido em minutos pelo passo temporal:

$$\text{lag}_{\min} = \ell^* \cdot \Delta t$$

Convenção: lag positivo significa que o indicador **antecede** o indicador-chave (a causa ocorre antes do efeito).

5. Informação Mútua (relações não-lineares)

Além da correlação linear, mede-se a dependência (inclusive não-linear) entre o indicador no lag ótimo e o indicador-chave pela Informação Mútua:

$$I(X; Y) = \sum_x \sum_y p(x, y) \log \frac{p(x, y)}{p(x)p(y)}$$

Valores próximos de zero indicam independência; valores maiores indicam dependência mais forte. É estimada por k-vizinhos (scikit-learn, *mutual_info_regression*).

6. Atribuição rigorosa de variância (Shapley / LMG)

A correlação individual superestima o impacto quando há indicadores correlacionados entre si. Para dar a cada driver uma **fatia real e não-sobreposta** da variância do indicador-chave, monta-se uma regressão linear múltipla com os indicadores alinhados pelo seu lag ótimo e decompõe-se o coeficiente de determinação.

6.1. Coeficiente de determinação (R^2)

Para um conjunto de preditores, o R^2 mede a fração da variância do indicador-chave explicada pelo modelo:

$$R^2 = 1 - \frac{\sum_i (y_i - \hat{y}_i)^2}{\sum_i (y_i - \bar{y})^2}$$

6.2. Multicolinearidade (VIF) e sua eliminação

O Fator de Inflação da Variância mede o quanto um indicador é redundante em relação aos demais. Sendo R_j^2 o R^2 da regressão do indicador j contra os outros:

$$\text{VIF}_j = \frac{1}{1 - R_j^2}$$

VIF alto (tipicamente > 10) indica forte redundância. Quando a eliminação está ativa, o programa: (i) agrupa indicadores com correlação mútua $|\text{corr}| \geq 0,90$, mantendo em cada grupo o mais relacionado ao indicador-chave; e (ii) remove iterativamente o de maior VIF enquanto exceder o limiar. Os removidos são reportados.

6.3. Decomposição de Shapley / LMG

A fatia de cada indicador i é a média da sua contribuição marginal ao R^2 sobre todos os subconjuntos S dos demais preditores (valor de Shapley aplicado ao R^2). Com p preditores e N o conjunto completo:

$$\phi_i = \sum_{S \subseteq N \setminus \{i\}} \frac{|S|! (p - |S| - 1)!}{p!} [R^2(S \cup \{i\}) - R^2(S)]$$

Essa decomposição tem três propriedades fundamentais: as fatias são **não-negativas**, **não-sobrepostas** e **somam exatamente o R^2 do modelo completo**:

$$\sum_{i=1}^p \phi_i = R^2(N)$$

Para até 10 preditores o cálculo é exato (todos os subconjuntos); acima disso, aproxima-se por amostragem de permutações aleatórias (mesma esperança).

6.4. Métricas exibidas

A partir das fatias ϕ , o painel mostra:

Fatia da variância (parcela real da variação do indicador-chave atribuída ao driver):

$$\text{Fatia}_i (\%) = 100 \cdot \phi_i$$

Contribuição no modelo (a mesma fatia normalizada para somar 100%):

$$\text{Contrib}_i (\%) = 100 \cdot \frac{\phi_i}{R^2(N)}$$

Na aba de análise detalhada também é exibido o impacto simples por indicador (R^2 individual = correlação ao quadrado):

$$\text{Impacto}_i (\%) = 100 \cdot r_i^2$$

7. Cálculo de estabilidade de um indicador

A estabilidade é avaliada no **período todo analisado** pelo **coeficiente de variação** (CV), métrica padrão de estabilidade de processo: mede o quanto o indicador oscilou em relação ao seu nível típico. Sendo σ o desvio padrão e μ a média da série:

$$CV = \frac{\sigma}{|\mu|}$$

A classificação usa dois limiares (o limiar de variação forte é ajustável no aplicativo; valores padrão abaixo):

- **Estável:** $CV < 5\%$;
- **Moderada:** $5\% \leq CV < 15\%$;
- **Instável (variação forte):** $CV \geq 15\%$.

A tendência líquida do período é o sinal da diferença entre a média do último e do primeiro terço da série:

$$\text{tend} = \text{sinal}(\bar{x}_{\text{fim}} - \bar{x}_{\text{ini}})$$

O CV não é uma medida válida quando a série cruza o zero (nível mal definido / média próxima de zero); nesses casos a estabilidade é reportada como '—'.

8. Detecção do maior distúrbio (evidência causa→efeito)

Para o gráfico de evidência, localiza-se o maior distúrbio histórico do driver pelo z-score ponto a ponto:

$$z_t = \frac{x_t - \bar{x}}{\sigma_x}, \quad t^* = \operatorname{argmax}_t |z_t|$$

A janela da causa é o trecho contíguo em torno do pico onde o z-score permanece relevante, $|z_t| \geq \max(0,5 \cdot |z(t^*)|, 1,5)$. A janela de efeito é a janela da causa deslocada para frente pelo lag — evidenciando, na linha de tempo real, qual trecho do driver impactou o indicador-chave.

9. Gatilhos acionáveis

Um gatilho é emitido quando um driver que **antecede** o indicador-chave ($\text{lag} > 0$) apresentou **forte variação no período todo** ($\text{CV} \geq \text{limiar configurável}$). O sentido provável do indicador-chave combina a tendência do driver no período com o sinal da correlação no lag ótimo:

$$\text{dir}_{\text{chave}} = \text{sinal}(\text{tend}) \cdot \text{sinal}(r(\ell^*))$$

Assim, o painel destaca os indicadores que mais variaram no período e que, por anteciparem o indicador-chave, são as prováveis causas a monitorar — indicando o sentido da influência e a fatia de impacto correspondente.

10. Premissas e limitações

- Correlação não implica causalidade; o lag e o conhecimento de processo ajudam a sustentar a interpretação causal.
- A detecção de lag pressupõe séries razoavelmente estacionárias; séries com forte tendência podem deslocar o pico de correlação.
- No modo laboratório, a resolução de lag é limitada ao período de composição (ex.: 4 horas) — atrasos menores não são detectáveis.
- A atribuição de Shapley pressupõe relação aproximadamente linear no modelo de regressão usado para o R^2 .

Documento gerado automaticamente a partir do código-fonte do programa (analysis.py / app.py).